



UNIVERSIDADE FEDERAL DO TOCANTINS
CAMPUS UNIVERSITÁRIO DE PALMAS
CURSO DE CIÊNCIAS ECONÔMICAS

PEDRO VICTOR DE SÁ CASTRO

XXX

Palmas, TO
2026

Pedro Victor de Sá Castro

XXX

Monografia apresentada à Universidade
Federal do Tocantins (UFT), Campus
Universitário de Palmas para obtenção do
título de bacharel em Ciências Econômicas

Orientador: Marcleiton Ribeiro Moraes

Palmas, TO
2026

AGRADECIMENTOS

Página para agradecimientos

RESUMO

Resumo

ABSTRACT

Abstract

SUMÁRIO

1	INTRODUÇÃO	7
2	REFERENCIAL TEÓRICO	8
3	METODOLOGIA	10
3.1	Base de dados	11
3.2	Estratégia empírica	12
4	Resultados	13
5	Conclusão	17

LISTA DE ABREVIATURAS E SIGLAS

SAEB Sistema de Avaliação da Educação Básica. 7, 8, 11–14

1 INTRODUÇÃO

O panorama educacional brasileiro nas últimas décadas revela avanços em cobertura escolar, mas persistem desafios em termos de qualidade e equidade. Embora tenha havido aumento na escolaridade média da população, a proficiência em habilidades básicas ainda é insuficiente em muitas regiões do país. A heterogeneidade regional é refletida em desigualdades de renda, gasto público em educação e infraestrutura escolar que contribuem para diferenças significativas no desempenho dos estudantes entre estados e municípios.

O choque provocado pela pandemia de Covid-19 representou um evento exógeno de grande magnitude sobre o processo educativo. A interrupção das atividades presenciais, a adoção heterogênea de práticas remotas (síncronas e assíncronas) e o retorno gradual e desigual às aulas presenciais afetaram o acesso e a continuidade do aprendizado. A edição de 2021 do SAEB, aplicada em contexto pandêmico, registrou queda nas proficiências médias em diversos anos escolares, evidenciando perdas de aprendizagem que se distribuíram de modo desigual entre grupos socioeconômicos e localidades ([Estudos e Pesquisas Educacionais Anísio Teixeira \(Inep\), 2021](#)).

Considerando esse contexto, em que medida as diferentes estratégias adotadas por unidades federativas e municípios durante a pandemia, em particular a oferta de aulas remotas assíncronas e o momento de retorno às aulas presenciais explicam as variações observadas nos resultados do SAEB em 2021? A hipótese investigada é que unidades que implementaram respostas educacionais mais estruturadas durante o período de emergência, por exemplo, oferta de conteúdo remoto de qualidade e retorno mais rápido com protocolos, sofreram menores perdas de aprendizagem do que aquelas com respostas menos organizadas.

O objetivo deste trabalho é analisar o impacto das estratégias de resposta educacional à pandemia sobre os resultados de aprendizagem medidos pelo SAEB em 2021, com ênfase em comparar unidades e municípios que adotaram diferentes combinações de modalidades remotas e cronogramas de retorno presencial.

Estudar o efeito das estratégias de resposta educacional a um choque exógeno é relevante por múltiplas razões. Primeiro, entender que políticas minimizam perdas de aprendizagem pode orientar ações prioritárias, alocação de recursos e programas para minimizar impactos negativos. Segundo, a avaliação das práticas implementadas durante a pandemia fornece um aprendizado para aumentar a resiliência do sistema educacional frente a choques futuros (por exemplo, crises sanitárias ou desastres naturais). Finalmente, ao relacionar as variações do SAEB com determinantes socioeconômicos, este trabalho contribui para entender a relação entre capital humano e desigualdade educacional no

Brasil, retomando debates clássicos sobre retorno à educação e crescimento econômico (Becker, 1975; Chaves; Silva; Carvalho Silva, 2019; Fraga; Bacha, 2013).

O capítulo 2 apresenta o referencial teórico e evidências empíricas sobre capital humano e educação. Em seguida, a seção de metodologia descreve as bases de dados (incluindo os microdados do SAEB e fontes sobre as respostas à pandemia), os tratamentos aplicados. Por fim, são apresentados os resultados e as conclusões.

2 REFERENCIAL TEÓRICO

Na Economia, capital humano pode ser entendido como o estoque de competências e habilidades incorporadas aos indivíduos (por exemplo, habilidades cognitivas, socioemocionais e conhecimentos escolares) que aumentam a produtividade e se refletem em melhores resultados no mercado de trabalho e no bem-estar. A formulação moderna dessa ideia se consolida quando a educação passa a ser tratada como um investimento, e não apenas como consumo. É chamado de “capital humano” porque o investimento é feito no indivíduo (através de educação) e, portanto, não pode ser separado dele (Becker, 1975, p. 16).

Schultz (1961) é um dos autores centrais ao argumentar que gastos com educação e outras formas de qualificação são investimentos que elevam a capacidade produtiva e ajudam a explicar diferenças de renda e desenvolvimento. Embora fosse óbvio que as pessoas adquirissem habilidades e conhecimentos, não era evidente que esses conhecimentos constituíssem uma forma de capital.

Schultz (1961) observou que o aumento na produção nacional por pessoa foi maior que o aumento de terra, horas de trabalho e capital físico por pessoa. Logo, o investimento em capital humano é a provável explicação para essa diferença. O consumo na verdade constitui investimento em capital humano. Os gastos com educação, saúde e migração interna buscando melhores oportunidades de trabalho são investimentos. O capital humano é muito comum a outras formas de capital, no entanto, ele tem alguns aspectos diferentes.

Schultz (1961, p. 9) apresenta os cinco principais tipos de investimento em capital humano:

- Educação formal e escolaridade desde a escola primária até o ensino superior
- Treinamento no trabalho: aprendizado formal e informal, orientação e prática no próprio emprego
- Saúde: gastos com serviços médicos, nutrição e saneamento básico que aumentam a

expectativa de vida, a força de trabalho e a produtividade.

- Migração para ajustar-se a melhores oportunidades de emprego: mover-se para locais com melhores perspectivas de trabalho e salários.
- Informação sobre o mercado de trabalho e as oportunidades econômicas: tempo e recursos gastos para saber onde e como utilizar melhor suas habilidades.

Todos esses investimentos aumentam a capacidade produtiva das pessoas. Todos eles envolvem custos financeiros e de tempo, e os ganhos futuros geralmente compensam.

A educação como investimento é uma abordagem formalizada por [Becker \(1975\)](#). A educação é vista como investimento com custos presentes (mensalidades, material e tempo) e benefícios futuros (maior produtividade, salários mais altos, menor risco de desemprego). Nesse arcabouço, indivíduos e famílias comparam custos e retornos esperados ao longo do ciclo de vida, e a escolaridade resulta de uma decisão intertemporal sob restrições.

No modelo de [Becker \(1975\)](#) a escolaridade é uma decisão econômica semelhante a comprar uma máquina. A pessoa escolhe quanto investir em capital humano comparando custos e o retorno esperado ao longo da vida. O investimento é feito quando o valor presente dos benefícios é maior que o custo total. Os custos de investimento são dois: o custo direto, que inclui mensalidade, material, transporte etc., e o custo de oportunidade, que é a renda que a pessoa deixa de ganhar por estar estudando. O retorno esperado decorre do fato de que a educação aumenta a produtividade e tende a elevar o salário no futuro, aumentar a probabilidade de emprego e melhorar a progressão de carreira.

A condição básica é comparar o valor presente dos recebimentos futuros com o valor presente dos gastos.

$$\sum_{t=0}^{n-1} \frac{R_t}{(1+i)^{t+1}} = \sum_{t=0}^{n-1} \frac{E_t}{(1+i)^{t+1}}$$

- R_t : recebimentos futuros no período t
- E_t : gastos ou custos no período t
- i : taxa de desconto ou taxa de juros
- n : número de períodos considerados

O investimento em capital humano é realizado quando o valor presente dos benefícios futuros é maior que o valor presente dos custos, isto é: $\sum_{t=0}^{n-1} \frac{R_t}{(1+i)^{t+1}} > \sum_{t=0}^{n-1} \frac{E_t}{(1+i)^{t+1}}$

Essa estrutura permite compreender a aprendizagem escolar como parte do processo de acumulação de capital humano, de modo que choques educacionais, como a interrupção das aulas presenciais durante a pandemia, podem afetar o estoque de habilidades dos estudantes e, conseqüentemente, seus retornos futuros.

Mincer (1974) fez um trabalho inovador utilizando dados dos Censos de 1950 e 1960 para analisar a distribuição de renda com a escolaridade. Até o momento não existiam evidências quantitativas dos efeitos do investimento em capital humano sobre os rendimentos. Seu trabalho incorpora o investimento pós-escolar, que inclui a experiência de trabalho e investimentos pós-escolares, como treinamento no trabalho. Seu modelo consegue explicar melhor os rendimentos ao considerar a experiência de trabalho. Os rendimentos crescem com a experiência. O retorno à educação é melhor estimado ao analisar os rendimentos após um período constante de experiência.

Em seu artigo seminal *Schooling, Experience, and Earnings* (1974), Mincer postula que investimentos em educação aumentam a produtividade dos trabalhadores e, conseqüentemente, seus rendimentos futuros. O modelo canônico de Mincer (1974) expressa essa relação através da equação:

$$\ln(W_i) = \beta_0 + \beta_1 S_i + \beta_2 \text{Exp}_i + \beta_3 \text{Exp}_i^2 + \varepsilon_i \quad (1)$$

Na equação 1¹, o salário do indivíduo W_i é explicado pelos anos de escolaridade (S_i), pela experiência no mercado de trabalho em anos (Exp_i) e pelo termo quadrático da experiência (Exp_i^2). O coeficiente β_1 representa a taxa de retorno da educação. O termo Exp_i^2 é incluído porque os rendimentos tendem a crescer com a experiência, mas em ritmo decrescente. Por fim, ε_i é o termo de erro e reúne fatores não observados que afetam o salário.

Assim, choques que reduzem o processo de aprendizagem, como interrupções prolongadas, baixa efetividade do ensino remoto ou retornos presenciais tardios podem diminuir o acúmulo de capital humano, mesmo que os alunos permaneçam matriculados formalmente.

3 METODOLOGIA

Esta pesquisa utiliza uma estratégia quantitativa para investigar se a ausência de estratégias não presenciais de ensino durante a pandemia de Covid-19 esteve associada

¹O uso do logaritmo natural ($\ln$) é para interpretar os coeficientes em termos percentuais, isto é, como retorno percentual de um ano adicional de educação.

a perdas adicionais de aprendizagem nos municípios brasileiros. A análise combina informações da pesquisa *Resposta Educacional à Pandemia de Covid-19 no Brasil*, do Censo Escolar, com dados de desempenho do SAEB. O objetivo empírico é comparar a evolução do desempenho escolar de municípios com diferentes respostas educacionais antes e depois do choque provocado pela pandemia.

A unidade de análise adotada é o município ao longo do tempo. A escolha do nível municipal decorre de duas razões. Primeiro, a sinopse estatística da resposta educacional à pandemia disponibiliza informações agregadas por município, localização e dependência administrativa. Segundo, a utilização de municípios, em vez de apenas unidades da federação, aumenta o número de observações e permite explorar maior variação nas estratégias adotadas pelas redes de ensino.

3.1 Base de dados

A principal fonte para identificar as estratégias educacionais adotadas durante a pandemia é a Sinopse Estatística da Pesquisa *Resposta Educacional à Pandemia de Covid-19*, divulgada pelo Inep a partir do Censo Escolar da Educação Básica ([Estudos e Pesquisas Educacionais Anísio Teixeira \(Inep\), 2021](#)). A base utilizada é a planilha de estabelecimentos de ensino, especificamente a aba “1.1 a 1.3”, que contém informações sobre ajustes no calendário escolar, suspensão das atividades presenciais e realização de atividades de ensino-aprendizagem não presenciais.

O tratamento da planilha segue quatro etapas. Primeiro, o arquivo em formato `xlsx` é carregado no Python com a biblioteca `pandas`, ignorando as linhas iniciais de cabeçalho da sinopse. Em seguida, o código do município (`CO_MUNICIPIO`) é convertido para formato numérico inteiro, permitindo a compatibilização com as demais bases municipais. Depois, são mantidas apenas as observações com município identificado, localização total (`TP_LOCALIZACAO = Total`) e dependências administrativas desagregadas, excluindo as linhas agregadas “Total” e “Pública” porque o objetivo é analisar redes desagregadas. Por fim, utiliza-se a variável `PERC_QUEST_3_S`, que informa o percentual de escolas que responderam afirmativamente à pergunta sobre adoção de estratégias não presenciais durante o período de suspensão das atividades presenciais. Todo o processo de tratamento está disponível em <https://github.com/aspeddrotcc>.

Com base nessa variável, define-se o grupo de tratamento como o conjunto de municípios em que menos de 20% das escolas da dependência administrativa observada declararam ter adotado estratégias não presenciais de ensino-aprendizagem. Esse critério identifica 58 municípios. Assim, neste trabalho, o indicador de tratamento representa uma

exposição negativa: estar no grupo tratado significa pertencer ao conjunto de municípios com baixa adoção, ou ausência quase generalizada, de estratégias não presenciais. O grupo de controle é composto pelos demais municípios, isto é, aqueles em que a proporção de escolas que adotaram estratégias não presenciais foi igual ou superior ao limite definido.

Os resultados educacionais são obtidos a partir dos dados municipais do SAEB, disponibilizados via [Base dos Dados \(s.d.\)](#). As variáveis dependentes principais são as proficiências médias em Língua Portuguesa e Matemática, calculadas como a média das notas do 5º e do 9º anos do ensino fundamental, para as redes federal, estadual, municipal e privada e localização total. A opção por agregar 5º e 9º anos busca captar uma medida sintética do desempenho no ensino fundamental, reduzindo a dependência de resultados de apenas uma etapa escolar. A análise considera 2021 como período pós-tratamento, pois corresponde à edição do SAEB aplicada após o choque pandêmico e durante o processo de retomada das atividades presenciais.

3.2 Estratégia empírica

A estratégia empírica utiliza o método de diferenças em diferenças (*difference-in-differences*, DiD). Esse método compara a variação do desempenho escolar antes e depois da pandemia entre dois grupos: municípios com baixa adoção de estratégias não presenciais e municípios que adotaram algum grau de resposta educacional não presencial. A ideia central é que, se os dois grupos apresentavam trajetórias semelhantes antes da pandemia, a diferença entre suas variações após o choque pode ser interpretada como o efeito relativo da baixa adoção de estratégias educacionais.

O modelo básico estimado é dado por:

$$Y_{it} = \beta_0 + \beta_1 D_i + \beta_2 P_t + \beta_3 (D_i \times P_t) + \varepsilon_{it} \quad (2)$$

em que Y_{it} representa a proficiência média no SAEB do município i no ano t ; D_i é uma variável binária dada por:

$$D_i = \begin{cases} 1 & \text{para municípios com menos de 20\% das escolas adotando estratégias; esses municípios são considerados sem estratégia e compõem o grupo de tratamento} \\ 0 & \text{caso contrário} \end{cases} \quad (3)$$

P_t é uma variável binária igual a 1 no período pós-pandemia, definido pela edição de 2021 do SAEB; e $D_i \times P_t$ é o termo de interação que identifica o estimador de diferenças

em diferenças. O termo ε_{it} representa os fatores não observados que afetam o desempenho municipal.

O coeficiente de interesse é β_3 . Ele mede a diferença entre a variação do desempenho dos municípios tratados e a variação do desempenho dos municípios de controle:

$$\beta_3 = (\bar{Y}_{T,2021} - \bar{Y}_{T,pre}) - (\bar{Y}_{C,2021} - \bar{Y}_{C,pre}) \quad (4)$$

em que T indica o grupo tratado, C indica o grupo de controle e pre representa o período anterior à pandemia. Como o tratamento é definido pela baixa adoção de estratégias não presenciais, um coeficiente β_3 negativo indica que os municípios tratados tiveram perda adicional de proficiência em relação aos municípios com maior adoção de estratégias. Um coeficiente positivo indicaria melhora relativa do grupo tratado, resultado que seria contrário à hipótese principal do trabalho.

4 Resultados

Esta seção apresenta os resultados da análise descritiva das tendências e da estimação do modelo de diferenças em diferenças para Língua Portuguesa e Matemática. Em ambos os casos, a variável dependente é a nota média municipal no SAEB, calculada a partir das médias do 5º e do 9º anos do ensino fundamental. O grupo tratado corresponde aos municípios com baixa adoção de estratégias não presenciais durante a suspensão das aulas presenciais.

As Figuras 1 e 2 apresentam a evolução das notas médias para Língua Portuguesa e Matemática, respectivamente. Em ambas as disciplinas, os municípios classificados como sem estratégia apresentam desempenho médio inferior ao dos municípios com estratégia em todos os anos observados. Essa diferença persistente de nível indica que os grupos já eram distintos antes da pandemia, o que recomenda cautela na interpretação causal dos resultados.

Apesar dessa diferença, as séries apresentam movimentos semelhantes em parte do período anterior ao choque, com aumento das médias até 2019. Em 2021, primeiro ano observado após o início da pandemia, há queda nas duas disciplinas e nos dois grupos. A queda é visualmente mais acentuada no grupo sem estratégia, tanto em Língua Portuguesa quanto em Matemática. Esse padrão é compatível com a hipótese de que a baixa adoção de estratégias não presenciais esteve associada a perdas adicionais de aprendizagem.

A Tabela 1 apresenta o resultado do modelo para Língua Portuguesa. O coeficiente da variável `sem_estrategia` é negativo e estatisticamente significativo, igual a -19,7651.




Figura 1: Evolução da nota média do SAEB em Língua Portuguesa (5º e 9º anos)




Figura 2: Evolução da nota média do SAEB em Matemática (5º e 9º anos)

Tabela 1: Resultado do modelo de diferenças em diferenças para Língua Portuguesa

Dep. Variable:	media	R-squared:	0.010
Model:	OLS	Adj. R-squared:	0.010
Method:	Least Squares	F-statistic:	82.92
Date:	Fri, 12 Jun 2026	Prob (F-statistic):	1.77e-52
Time:	22:21:59	Log-Likelihood:	-1.7099e+05
No. Observations:	38535	AIC:	3.420e+05
Df Residuals:	38531	BIC:	3.420e+05
Df Model:	3		
Covariance Type:	cluster		

	coef	std err	z	P> z	[0.025	0.975]
Intercept	223.7410	0.230	971.161	0.000	223.289	224.193
sem_estrategia	-19.7651	1.397	-14.151	0.000	-22.503	-17.028
pos	0.8518	0.168	5.062	0.000	0.522	1.182
did	-4.0563	1.789	-2.268	0.023	-7.562	-0.551

Omnibus:	260.198	Durbin-Watson:	1.445
Prob(Omnibus):	0.000	Jarque-Bera (JB):	265.067
Skew:	-0.201	Prob(JB):	2.76e-58
Kurtosis:	2.948	Cond. No.	29.0

Notes:

[1] Standard Errors are robust to cluster correlation (cluster)

Isso indica que, antes de considerar o efeito específico de 2021, os municípios classificados no grupo sem estratégia já apresentavam média cerca de 19,77 pontos inferior à dos municípios do grupo de controle.

O coeficiente da variável **pos** é positivo, igual a 0,8518, e estatisticamente significativo. Esse coeficiente representa a variação média do grupo de controle no período pós-tratamento, mantendo fixa a diferença média entre tratados e controles. O coeficiente de interesse, associado ao termo **did**, é igual a -4,0563, com p-valor de 0,023. Como esse coeficiente é negativo e estatisticamente significativo ao nível de 5%, o resultado sugere que os municípios sem estratégia tiveram perda adicional de aproximadamente 4,06 pontos em Língua Portuguesa, em relação aos municípios com estratégia.

Tabela 2: Resultado do modelo de diferenças em diferenças para Matemática

Dep. Variable:	media	R-squared:	0.014
Model:	OLS	Adj. R-squared:	0.014
Method:	Least Squares	F-statistic:	221.0
Date:	Fri, 12 Jun 2026	Prob (F-statistic):	1.77e-135
Time:	22:21:59	Log-Likelihood:	-1.7301e+05
No. Observations:	38535	AIC:	3.460e+05
Df Residuals:	38531	BIC:	3.461e+05
Df Model:	3		
Covariance Type:	cluster		

	coef	std err	z	P> z 	[0.025	0.975]
Intercept	233.2632	0.259	900.818	0.000	232.756	233.771
sem_estrategia	-22.2245	1.366	-16.264	0.000	-24.903	-19.546
pos	-3.0346	0.164	-18.495	0.000	-3.356	-2.713
did	-2.9667	1.725	-1.720	0.085	-6.347	0.413

Omnibus:	18.495	Durbin-Watson:	1.459
Prob(Omnibus):	0.000	Jarque-Bera (JB):	20.421
Skew:	-0.003	Prob(JB):	3.68e-05
Kurtosis:	3.113	Cond. No.	29.0

Notes:

[1] Standard Errors are robust to cluster correlation (cluster)

A Tabela 2 apresenta o resultado do modelo para Matemática. Assim como em Língua Portuguesa, o coeficiente da variável **sem_estrategia** é negativo e estatisticamente significativo, igual a -22,2245. Esse resultado indica que os municípios sem estratégia já apresentavam média cerca de 22,22 pontos inferior à dos municípios com estratégia antes de considerar o efeito específico do período pós-pandemia.

O coeficiente da variável **pos** é negativo, igual a -3,0346, e estatisticamente significa-

tivo, indicando queda média no grupo de controle no período pós-tratamento. O coeficiente de interesse, `did`, é igual a -2,9667, com p-valor de 0,085. Portanto, o efeito estimado para Matemática também é negativo, indicando perda adicional de aproximadamente 2,97 pontos para os municípios sem estratégia. No entanto, esse resultado é estatisticamente significativo apenas ao nível de 10%, e não a 5%.

Em conjunto, os resultados apontam para pior evolução relativa dos municípios com baixa adoção de estratégias não presenciais nas duas disciplinas analisadas. A evidência é mais forte para Língua Portuguesa, onde o coeficiente de diferenças em diferenças é significativo a 5%. Em Matemática, o sinal do coeficiente é compatível com a hipótese do trabalho, mas a evidência estatística é mais fraca. Além disso, a magnitude dos coeficientes de `sem_estrategia` confirma que os grupos já eram substancialmente diferentes antes da pandemia. Assim, os resultados devem ser interpretados como evidência de associação entre baixa adoção de estratégias educacionais e pior evolução do desempenho, com cautela quanto a uma interpretação causal forte.

5 Conclusão

REFERÊNCIAS

BASE DOS DADOS. **Base dos Dados**. [S. l.: s. n.]. Disponível em: <https://github.com/basedosdados/sdk>.

BECKER, Gary S. Human Capital: A Theoretical and Empirical Analysis, with Special Reference to Education — Front Matter. *In*: HUMAN Capital: A Theoretical and Empirical Analysis, with Special Reference to Education (2nd ed.) 2. ed. New York: National Bureau of Economic Research / Columbia University Press, 1975. Acessado em 19/10/2025. ISBN 0-87014-513-4. Disponível em: <https://www.nber.org/system/files/chapters/c3730/c3730.pdf>.

CHAVES, Marcelo Santos; SILVA, David Costa Correia;
CARVALHO SILVA, Charlene de. **A Relação da Formação de Capital Humano com o Desempenho Econômico Brasileiro**. [S. l.], jan. 2019. (Planejamento e Políticas Públicas (PPP), 52). Acessado em 18/10/2025. Disponível em: <https://repositorio.ipea.gov.br/server/api/core/bitstreams/41bf00f5-8805-4ae4-bc5b-0406d34bea9c/content>.

ESTUDOS E PESQUISAS EDUCACIONAIS ANÍSIO TEIXEIRA (INEP), Instituto Nacional de. **Resultados do Questionário “Resposta Educacional à Pandemia de Covid-19 no Brasil” – Censo Escolar da Educação Básica 2020**. [S. l.], 2021. Acessado em 20/10/2025. Disponível em: https://download.inep.gov.br/censo_escolar/resultados/2020/apresentacao_pesquisa_covid19_censo_escolar_2020.pdf.

FRAGA, Gilberto Joaquim; BACHA, Carlos José Caetano. Abertura comercial, capital humano e crescimento econômico no Brasil. **Pesquisa e Planejamento Econômico**, v. 43, n. 2, p. 384–418, 2013. Acessado em 19/10/2025. Disponível em: <https://repositorio.ipea.gov.br/entities/publication/c4510f51-d83e-4f67-8e50-b877d84a0657>.

MINCER, Jacob A. Schooling, Experience, and Earnings. **National Bureau of Economic Research (NBER)**, 1974. Accessed: 2026-01-28. Disponível em: <https://www.nber.org/books-and-chapters/schooling-experience-and-earnings>.

SCHULTZ, Theodore W. Investment in Human Capital. **The American Economic Review**, American Economic Association, v. 51, n. 1, p. 1–17, 1961. ISSN 00028282. Disponível em: <https://la.utexas.edu/users/hcleaver/330T/350kPEESchultzInvestmentHumanCapital.pdf>. Acesso em: 18 jan. 2026.