



UNIVERSIDADE FEDERAL DO TOCANTINS
CAMPUS UNIVERSITÁRIO DE PALMAS
CURSO DE CIÊNCIAS ECONÔMICAS

PEDRO VICTOR DE SÁ CASTRO

XXX

Palmas, TO
2026

Pedro Victor de Sá Castro

XXX

Monografia apresentada à Universidade
Federal do Tocantins (UFT), Campus
Universitário de Palmas para obtenção do
título de bacharel em Ciências Econômicas

Orientador: Marcleiton Ribeiro Moraes

Palmas, TO
2026

AGRADECIMENTOS

Página para agradecimientos

RESUMO

Resumo

ABSTRACT

Abstract

SUMÁRIO

1	INTRODUÇÃO	7
1.1	IMPACTOS DA PANDEMIA SOBRE A EDUCAÇÃO BÁSICA	8
2	REFERENCIAL TEÓRICO	11
3	METODOLOGIA	14
3.1	Base de dados	14
3.2	Estratégia empírica	17
4	Resultados	19
5	Conclusão	23

LISTA DE ABREVIATURAS E SIGLAS

INEP Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira. 14, 15

SAEB Sistema de Avaliação da Educação Básica. 7, 10, 14–17, 19, 20

SQL Structured Query Language. 15

1 INTRODUÇÃO

O panorama educacional brasileiro nas últimas décadas revela avanços em cobertura escolar, mas persistem desafios em termos de qualidade e equidade. Embora tenha havido aumento na escolaridade média da população, a proficiência em habilidades básicas ainda é insuficiente em muitas regiões do país. A heterogeneidade regional se reflete em desigualdades de renda, diferenças nos gastos públicos em educação e disparidades de infraestrutura escolar, fatores que contribuem para diferenças significativas no desempenho dos estudantes entre estados e municípios.

O choque provocado pela pandemia de Covid-19 representou um evento exógeno de grande magnitude sobre o processo educativo. A interrupção das atividades presenciais, a adoção heterogênea de práticas remotas (síncronas e assíncronas) e o retorno gradual e desigual às aulas presenciais afetaram o acesso e a continuidade do aprendizado. A edição de 2021 do SAEB, aplicada em contexto pandêmico, registrou queda nas proficiências médias em diversos anos escolares, evidenciando perdas de aprendizagem que se distribuíram de modo desigual entre redes de ensino e localidades ([Bof; Moraes, 2022](#)).

Considerando esse contexto, em que medida as diferentes estratégias adotadas por unidades federativas e municípios durante a pandemia, em particular a oferta de aulas remotas assíncronas e o momento de retorno às aulas presenciais, explicam as variações observadas nos resultados do SAEB em 2021? A hipótese investigada é que unidades que implementaram respostas educacionais mais estruturadas durante o período de emergência, tais como oferta de conteúdo remoto de qualidade e retorno mais rápido com protocolos sanitários, sofreram menores perdas de aprendizagem do que aquelas com respostas menos organizadas.

O objetivo deste trabalho é analisar o impacto das estratégias de resposta educacional à pandemia sobre os resultados de aprendizagem medidos pelo SAEB em 2021, com ênfase em comparar unidades e municípios que adotaram diferentes combinações de modalidades remotas e cronogramas de retorno presencial.

Estudar o efeito das estratégias de resposta educacional a um choque exógeno é relevante por múltiplas razões. Primeiro, entender que políticas minimizam perdas de aprendizagem pode orientar ações prioritárias, alocação de recursos e programas para minimizar impactos negativos. Segundo, a avaliação das práticas implementadas durante a pandemia fornece um aprendizado para aumentar a resiliência do sistema educacional frente a choques futuros (por exemplo, crises sanitárias ou desastres naturais). Finalmente, ao relacionar as variações do SAEB com determinantes socioeconômicos, este trabalho contribui para entender a relação entre capital humano e desigualdade educacional no

Brasil, retomando debates clássicos sobre retorno à educação e crescimento econômico (Becker, 1975; Chaves; Silva; Carvalho Silva, 2019; Fraga; Bacha, 2013).

A seção 1.1 discute os principais canais pelos quais a pandemia afetou a educação básica e explicita as desigualdades que condicionaram a continuidade do ensino. A seção 2 apresenta o referencial teórico e as evidências empíricas sobre capital humano e educação. Em seguida, a seção 3 descreve as bases de dados, os tratamentos aplicados e a estratégia empírica. Por fim, são apresentados os resultados e as conclusões.

1.1 IMPACTOS DA PANDEMIA SOBRE A EDUCAÇÃO BÁSICA

A pandemia de Covid-19 atingiu a educação básica por diferentes canais. Além da interrupção da oferta presencial, houve uma transferência abrupta de parte do processo de ensino para os domicílios, em um contexto no qual escolas, professores e famílias possuíam condições muito distintas para sustentar as atividades pedagógicas. O choque, portanto, não se restringiu ao fechamento das escolas: envolveu também redução do tempo efetivo de aprendizagem, dificuldades de interação entre professores e estudantes, risco de perda do vínculo escolar e ampliação de desigualdades que já existiam antes da crise sanitária.

A duração da interrupção foi expressiva. No ano letivo de 2020, 99,3% das escolas brasileiras suspenderam as atividades presenciais¹, e o período médio de suspensão chegou a 279 dias². Além disso, 90,1% das escolas não retornaram às atividades presenciais naquele ano³. Essa proporção alcançou 97,5% entre as escolas municipais e 70,9% entre as privadas⁴. Essas diferenças mostram que a exposição à interrupção não foi uniforme entre redes de ensino. Como os municípios respondem por parcela relevante da oferta dos anos iniciais do ensino fundamental, a capacidade das redes municipais de manter o contato com os alunos tornou-se especialmente importante para a continuidade da aprendizagem.

Embora mais de 98% das escolas tenham declarado a adoção de alguma estratégia

¹Fonte: Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep) (2021, p. 4), gráfico “Número de escolas de educação básica por condição de suspensão das atividades presenciais de ensino-aprendizagem no ano letivo de 2020 como medida de enfrentamento da pandemia de Covid-19 – Brasil 2020”.

²Fonte: Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep) (2021, p. 6), gráfico “Estatísticas do número de dias de suspensão das atividades presenciais de ensino-aprendizagem no ano letivo de 2020 como medida de enfrentamento da pandemia de Covid-19 – Brasil 2020”. O gráfico informa média de 279 dias para o total das escolas.

³O percentual total de 90,1% é informado pelo Inep no texto de divulgação que acompanha a apresentação, intitulado “Divulgados dados sobre impacto da pandemia na educação”.

⁴Fonte: Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep) (2021, p. 7), gráfico “Percentual de escolas que não retornou às atividades presenciais no ano letivo de 2020 – Brasil”.

não presencial⁵, a existência de uma estratégia não significa que ela tenha alcançado todos os estudantes ou reproduzido a quantidade e a qualidade da instrução presencial. Entre as escolas estaduais, 63,3% realizaram aulas ao vivo mediadas pela internet e com possibilidade de interação direta entre alunos e professores, enquanto a proporção foi de 27,4% nas municipais⁶. Também houve diferenças na preparação dos profissionais e na infraestrutura: 79,9% das escolas estaduais e 53,7% das municipais treinaram professores para o ensino não presencial, ao passo que somente 15,9% das estaduais e 2,2% das municipais adotaram medidas de acesso gratuito ou subsidiado à internet para os professores⁷. Assim, a resposta remota variou tanto em alcance quanto em recursos tecnológicos e possibilidades de interação.

As condições dos domicílios reforçaram essa heterogeneidade. Em novembro de 2020, 10,8% dos estudantes de 6 a 17 anos estavam sem aulas presenciais e sem atividades escolares. Na rede pública, essa proporção era de 12,4%, comparada a 2,9% na rede privada. Antes da pandemia, apenas 54,0% dos estudantes de 15 a 17 anos dispunham simultaneamente de internet e computador ou notebook em casa; o acesso alcançava 67,3% entre estudantes brancos e 46,8% entre estudantes pretos ou pardos ([Instituto Brasileiro de Geografia e Estatística \(IBGE\), 2021](#)). Desse modo, a substituição das aulas presenciais por atividades remotas transferiu para as famílias uma parcela dos custos de conectividade, equipamentos, espaço e apoio ao estudo, penalizando com maior intensidade os estudantes em situação socioeconômica vulnerável.

O problema também se manifestou na permanência escolar. Em novembro de 2020, mais de 5 milhões de crianças e adolescentes de 6 a 17 anos não tinham acesso à educação no Brasil, considerando aqueles que não frequentavam a escola ou que, embora matriculados, não recebiam atividades escolares. Mais de 40% desse grupo era formado por crianças de 6 a 10 anos, faixa etária cuja escolarização estava próxima da universalização antes da pandemia. O cenário representou risco de reversão de avanços obtidos nas duas décadas anteriores e atingiu principalmente grupos que já apresentavam maior vulnerabilidade social ([Fundo das Nações Unidas para a Infância \(UNICEF\); Centro de Estudos e Pesquisas](#)

⁵Fonte: [Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira \(Inep\) \(2021, p. 6\)](#), gráfico “Número de escolas de educação básica por condição de adoção de estratégias não presenciais de ensino no ano letivo de 2020 como medida de enfrentamento da pandemia de Covid-19 – Brasil 2020”.

⁶Fonte: [Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira \(Inep\) \(2021, p. 10\)](#), gráfico “Percentual de escolas por estratégia e ferramenta adotada no desenvolvimento das atividades de ensino-aprendizagem com os alunos durante a suspensão das atividades presenciais – Brasil 2020”.

⁷Fonte: [Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira \(Inep\) \(2021, p. 8\)](#), gráfico “Percentual de escolas por estratégia adotada pela escola/secretaria de educação junto aos professores para continuidade das atividades pedagógicas durante a suspensão das atividades presenciais – Brasil 2020”.

em Educação, Cultura e Ação Comunitária (Cenpec), 2021).

Os indícios de perda de aprendizado aparecem nos resultados do SAEB de 2021. A comparação com edições anteriores indica redução da proporção de alunos que alcançaram níveis adequados de proficiência em Língua Portuguesa e Matemática no 5º e no 9º anos do ensino fundamental e na 3ª série do ensino médio. Essa redução ocorreu conjuntamente com desigualdades relevantes entre redes de ensino, escolas urbanas e rurais e unidades da federação (Bof; Moraes, 2022). Contudo, a comparação direta entre 2019 e 2021 não separa, por si só, o efeito da pandemia de mudanças na participação dos estudantes na avaliação ou de outros fatores ocorridos no mesmo período. Essa limitação justifica o uso de uma estratégia econométrica que considere a trajetória anterior das notas e a heterogeneidade das respostas educacionais.

Na perspectiva da teoria do capital humano, as perdas podem persistir para além do período de fechamento. Habilidades escolares são acumuladas ao longo do tempo e servem de base para aprendizagens posteriores. Uma redução no estoque de conhecimentos, quando não compensada, pode afetar o processo de aprendizagem, a conclusão da educação básica e, no longo prazo, a produtividade e os rendimentos dos indivíduos. Por isso, o impacto econômico potencial não decorre somente dos dias sem aulas, mas da combinação entre duração da interrupção, efetividade das estratégias alternativas e capacidade de recuperação do aprendizado.

2 REFERENCIAL TEÓRICO

Na Economia, capital humano pode ser entendido como o estoque de competências e habilidades incorporadas aos indivíduos (por exemplo, habilidades cognitivas, socioemocionais e conhecimentos escolares) que aumentam a produtividade e se refletem em melhores resultados no mercado de trabalho e no bem-estar. A formulação moderna dessa ideia se consolida quando a educação passa a ser tratada como um investimento, e não apenas como consumo. Esse tipo de capital é chamado de “capital humano” porque o investimento é feito no indivíduo (por meio da educação) e, portanto, não pode ser separado dele (Becker, 1975, p. 16).

Schultz (1961) é um dos autores centrais ao argumentar que gastos com educação e outras formas de qualificação são investimentos que elevam a capacidade produtiva e ajudam a explicar diferenças de renda e desenvolvimento. Embora fosse evidente que as pessoas adquiriam habilidades e conhecimentos, não era evidente que esses conhecimentos constituíssem uma forma de capital.

Schultz (1961) observou que o aumento na produção nacional por pessoa foi maior que o aumento da disponibilidade de terra, das horas de trabalho e do capital físico por pessoa. Logo, o investimento em capital humano é a provável explicação para essa diferença. O consumo, na verdade, constitui investimento em capital humano. Os gastos com educação, saúde e migração interna buscando melhores oportunidades de trabalho são investimentos. O capital humano é semelhante a outras formas de capital, no entanto, ele tem alguns aspectos diferentes.

Schultz (1961, p. 9) apresenta os cinco principais tipos de investimento em capital humano:

- Educação formal e escolaridade desde a escola primária até o ensino superior
- Treinamento no trabalho: aprendizado formal e informal, orientação e prática no próprio emprego
- Saúde: gastos com serviços médicos, nutrição e saneamento básico que aumentam a expectativa de vida, a força de trabalho e a produtividade.
- Migração para ajustar-se a melhores oportunidades de emprego: mover-se para locais com melhores perspectivas de trabalho e salários.
- Informação sobre o mercado de trabalho e as oportunidades econômicas: tempo e recursos gastos para saber onde e como utilizar melhor suas habilidades.

Todos esses investimentos aumentam a capacidade produtiva das pessoas. Todos eles envolvem custos financeiros e de tempo, e os ganhos futuros geralmente compensam esses custos.

A educação como investimento é uma abordagem formalizada por [Becker \(1975\)](#). A educação é vista como investimento com custos presentes (mensalidades, material e tempo) e benefícios futuros (maior produtividade, salários mais altos, menor risco de desemprego). Nesse arcabouço, indivíduos e famílias comparam custos e retornos esperados ao longo do ciclo de vida, e a escolaridade resulta de uma decisão intertemporal sob restrições.

No modelo de [Becker \(1975\)](#) a escolaridade é uma decisão econômica semelhante a comprar uma máquina. A pessoa escolhe quanto investir em capital humano comparando custos e o retorno esperado ao longo da vida. O investimento é feito quando o valor presente dos benefícios é maior que o custo total. Os custos de investimento são dois: o custo direto, que inclui mensalidade, material, transporte etc., e o custo de oportunidade, que é a renda que a pessoa deixa de ganhar por estar estudando. O retorno esperado decorre do fato de que a educação aumenta a produtividade e tende a elevar o salário no futuro, aumentar a probabilidade de emprego e melhorar a progressão de carreira.

A condição básica é comparar o valor presente dos recebimentos futuros com o valor presente dos gastos.

$$\sum_{t=0}^{n-1} \frac{R_t}{(1+i)^{t+1}} = \sum_{t=0}^{n-1} \frac{E_t}{(1+i)^{t+1}}$$

- R_t : recebimentos futuros no período t
- E_t : gastos ou custos no período t
- i : taxa de desconto ou taxa de juros
- n : número de períodos considerados

O investimento em capital humano é realizado quando o valor presente dos benefícios futuros é maior que o valor presente dos custos, isto é: $\sum_{t=0}^{n-1} \frac{R_t}{(1+i)^{t+1}} > \sum_{t=0}^{n-1} \frac{E_t}{(1+i)^{t+1}}$

Essa estrutura permite compreender a aprendizagem escolar como parte do processo de acumulação de capital humano, de modo que choques educacionais, como a interrupção das aulas presenciais durante a pandemia, podem afetar o estoque de habilidades dos estudantes e, conseqüentemente, seus retornos futuros.

[Mincer \(1974\)](#) fez um trabalho inovador utilizando dados dos Censos de 1950 e 1960 para analisar a distribuição de renda com a escolaridade. Até o momento não

existiam evidências quantitativas dos efeitos do investimento em capital humano sobre os rendimentos. Seu trabalho incorpora o investimento pós-escolar, que inclui a experiência de trabalho e investimentos pós-escolares, como treinamento no trabalho. Seu modelo consegue explicar melhor os rendimentos ao considerar a experiência de trabalho. Os rendimentos crescem com a experiência. O retorno à educação é melhor estimado ao analisar os rendimentos após um período constante de experiência.

Em seu artigo seminal [Schooling, Experience, and Earnings \(1974\)](#), Mincer postula que investimentos em educação aumentam a produtividade dos trabalhadores e, conseqüentemente, seus rendimentos futuros. O modelo canônico de [Mincer \(1974\)](#) expressa essa relação por meio da equação:

$$\ln(W_i) = \beta_0 + \beta_1 S_i + \beta_2 \text{Exp}_i + \beta_3 \text{Exp}_i^2 + \varepsilon_i \quad (1)$$

Na equação 1 ⁸, o salário do indivíduo W_i é explicado pelos anos de escolaridade (S_i), pela experiência no mercado de trabalho em anos (Exp_i) e pelo termo quadrático da experiência (Exp_i^2). O coeficiente β_1 representa a taxa de retorno da educação. O termo Exp_i^2 é incluído porque os rendimentos tendem a crescer com a experiência, mas em ritmo decrescente. Por fim, ε_i é o termo de erro e reúne fatores não observados que afetam o salário.

Assim, choques que reduzem o processo de aprendizagem, como interrupções prolongadas, baixa efetividade do ensino remoto ou retornos presenciais tardios podem diminuir o acúmulo de capital humano, mesmo que os alunos permaneçam matriculados formalmente.

⁸O uso do logaritmo natural ($\ln$) é para interpretar os coeficientes em termos percentuais, isto é, como retorno percentual de um ano adicional de educação.

3 METODOLOGIA

Esta pesquisa adota uma estratégia quantitativa para investigar se a baixa adoção de estratégias não presenciais de ensino durante a pandemia de Covid-19 esteve associada a perdas adicionais de aprendizagem nos municípios brasileiros. A unidade de análise é o município observado ao longo do tempo. A opção pelo nível municipal decorre da disponibilidade das informações da pesquisa *Resposta Educacional à Pandemia de Covid-19 no Brasil* nesse nível de agregação e permite explorar maior variação nas respostas educacionais do que uma análise restrita às unidades da federação.

A rotina empírica foi desenvolvida em Python e está disponível em <https://github.com/aspeddro/tcc>, o arquivo `main.ipynb` realiza todo o procedimento de tratamento e análise. A manipulação dos dados utiliza principalmente as bibliotecas `pandas` e `numpy`. A leitura dos arquivos em planilha utiliza `openpyxl`. A consulta às bases públicas do INEP é feita por meio do pacote `basedosdados`. Os gráficos são produzidos com `matplotlib` e as estimações econométricas são realizadas com `statsmodels`. Os dados brutos ficam armazenados no diretório `raw_data/`, enquanto os gráficos e tabelas usados no texto são salvos no diretório `output/`.

3.1 Base de dados

A variável de tratamento é construída a partir da Sinopse Estatística da Pesquisa *Resposta Educacional à Pandemia de Covid-19*, divulgada pelo INEP a partir do Censo Escolar da Educação Básica (Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep), 2021). A planilha utilizada é a de estabelecimentos de ensino, especificamente a aba “1.1 a 1.3”, que contém informações sobre suspensão de atividades presenciais e adoção de estratégias não presenciais de ensino-aprendizagem durante a pandemia.

No tratamento dessa planilha, as linhas iniciais de cabeçalho da sinopse são desconsideradas e o código do município (`CO_MUNICIPIO`) é convertido para formato numérico inteiro, permitindo sua compatibilização com os dados do SAEB. Em seguida, são mantidas apenas as observações com município identificado, localização total (`TP_LOCALIZACAO = Total`) e dependências administrativas desagregadas. As categorias agregadas “Total” e “Pública” são excluídas para evitar dupla contagem das redes de ensino.

A informação central da sinopse é a variável `PERC_QUEST_3_S`, que informa o percentual de escolas que responderam afirmativamente à pergunta sobre adoção de estratégias não presenciais durante o período de suspensão das atividades presenciais. A Tabela 1 apresenta uma síntese da base de dados. Como a pergunta está formulada em termos

de adoção, valores menores indicam menor cobertura de estratégias remotas. Define-se, portanto, a variável binária `sem_estrategia`, igual a 1 para municípios em que menos de 20% das escolas declararam ter adotado estratégias não presenciais, e igual a 0 nos demais casos. Esse critério identifica 58 municípios no grupo tratado. O tratamento, portanto, representa uma exposição negativa: pertencer ao grupo tratado significa estar entre os municípios com baixa adoção, ou ausência quase generalizada, de estratégias não presenciais.

Tabela 1: Formato da Base de Dados do INEP

	CO_MUNICIPIO	TP_LOCALIZACAO	TP_DEPENDENCIA	PERC_QUEST_3_S
0	1100015	Total	Estadual	38.461538
1	1100015	Total	Municipal	100.000000
2	1100023	Total	Municipal	100.000000
3	1100023	Total	Privada	100.000000
4	1100031	Total	Municipal	75.000000
5	1100049	Total	Municipal	100.000000
6	1100049	Total	Privada	100.000000
7	1100056	Total	Municipal	100.000000
8	1100064	Total	Municipal	100.000000
9	1100072	Total	Municipal	100.000000

Se uma linha município/rede tem valor igual a 38, isso significa que 38% das escolas respondentes daquela agregação disseram que adotaram estratégias não presenciais durante a suspensão das aulas presenciais.

Fonte: Elaboração do autor.

Os resultados educacionais são obtidos a partir da tabela municipal do SAEB, disponibilizada pela [Base dos Dados \(s.d.\)](#). No notebook, os dados são consultados na tabela `basedosdados.br_inep_saeb_municipio`, mantendo observações de localização total, séries do 5º e 9º anos, redes federal, estadual, municipal e privada, e disciplinas de Língua Portuguesa e Matemática. Para cada município e ano, calcula-se a média da proficiência observada nas séries e redes selecionadas. Como a consulta direta à Base dos Dados exige projeto com faturamento no Google Cloud, os resultados da consulta foram salvos previamente nos arquivos `raw_data/saeb_lp.csv` e `raw_data/saeb_mt.csv`, que são lidos diretamente pelo notebook. O Código 1 apresenta a consulta SQL para ler os dados no Banco de Dados. A Tabela 2 tem uma síntese do resultado da consulta SQL.

Após a leitura dos arquivos do SAEB, os códigos municipais são convertidos para o mesmo tipo utilizado na sinopse e a variável `sem_estrategia` é atribuída aos municípios identificados no grupo tratado. A variável `pos` recebe valor 1 para a edição de 2021

Código 1: Consulta para calcular a média de proficiência em Língua Portuguesa no SAEB

```
select
    ano,
    id_municipio,
    round(avg(media), 2) as media, -- Media para o 5 e 9 ano
from basedosdados.br_inep_saeb.municipio
where localizacao = "total"
    and serie in (5, 9)
    and rede in ("federal", "estadual", "municipal", "privada")
    and disciplina = "LP"
group by ano, id_municipio
```

Tabela 2: Formato da Base de Dados do SAEB para Língua Portuguesa

	ano	id_municipio	media
0	2011	4304655	206.03
1	2011	4323507	234.97
2	2011	2108454	178.44
3	2011	2507101	184.74
4	2011	3537404	219.81
5	2011	2305226	184.09
6	2011	5205109	232.99
7	2011	2202083	199.93
8	2011	2602001	190.56
9	2011	2303956	198.18

Apenas as dez primeiras linhas. Fonte: Elaboração do autor.

do SAEB, ano de interesse da análise, e valor 0 para as demais observações usadas na estimação. Por fim, a variável `did` é criada pela multiplicação entre `sem_estrategia` e `pos`; esse termo de interação é o estimador de diferenças em diferenças utilizado nas regressões.

3.2 Estratégia empírica

A primeira etapa da análise é descritiva. Calcula-se a distribuição do percentual de escolas que adotaram estratégias não presenciais e identifica os municípios enquadrados no grupo tratado. Em seguida, são produzidos gráficos com a evolução da proficiência média no SAEB para municípios com e sem estratégia, separadamente para Língua Portuguesa e Matemática. Esses gráficos descrevem o comportamento dos grupos ao longo do tempo e funcionam como uma verificação visual da plausibilidade da hipótese de tendências paralelas.

A estimação econométrica utiliza o método de diferenças em diferenças (*difference-in-differences*, DiD). Esse método compara a variação do desempenho escolar entre dois grupos: municípios com baixa adoção de estratégias não presenciais e municípios com maior adoção de respostas educacionais durante a suspensão das aulas presenciais. A ideia central é que, se os grupos apresentavam trajetórias semelhantes antes do choque pandêmico, a diferença entre suas variações no ano de interesse pode ser interpretada como o efeito relativo da baixa adoção de estratégias não presenciais.

O modelo básico estimado é dado por:

$$Y_{it} = \beta_0 + \beta_1 D_i + \beta_2 P_t + \beta_3 (D_i \times P_t) + \varepsilon_{it} \quad (2)$$

em que Y_{it} representa a proficiência média no SAEB do município i no ano t ; D_i é uma variável binária dada por:

$$D_i = \begin{cases} 1 & \text{para municípios com menos de 20\% das escolas adotando} \\ & \text{estratégias não presenciais; esses municípios são conside-} \\ & \text{rados sem estratégia e compõem o grupo de tratamento} \\ 0 & \text{caso contrário} \end{cases} \quad (3)$$

P_t é uma variável binária igual a 1 para a edição de 2021 do SAEB e 0 para as demais observações utilizadas na estimação, $D_i \times P_t$ é o termo de interação que identifica o estimador de diferenças em diferenças. O termo ε_{it} representa os fatores não observados que afetam o desempenho municipal.

O coeficiente de interesse é β_3 . Ele mede a diferença entre a variação do desempenho dos municípios tratados e a variação do desempenho dos municípios de controle:

$$\beta_3 = (\bar{Y}_{T,P=1} - \bar{Y}_{T,P=0}) - (\bar{Y}_{C,P=1} - \bar{Y}_{C,P=0}) \quad (4)$$

em que T indica o grupo tratado, C indica o grupo de controle, $P = 1$ representa a edição de 2021 e $P = 0$ representa as demais observações usadas como comparação. O modelo é estimado por Mínimos Quadrados Ordinários, com erros-padrão clusterizados por município para considerar a correlação das observações de um mesmo município ao longo do tempo. Como o tratamento é definido pela baixa adoção de estratégias não presenciais, um coeficiente β_3 negativo indica que os municípios tratados tiveram perda adicional de proficiência em relação aos municípios com maior adoção de estratégias. Um coeficiente positivo indicaria melhora relativa do grupo tratado, resultado que seria contrário à hipótese principal do trabalho.

4 Resultados

Esta seção apresenta os resultados da análise descritiva das tendências e da estimação do modelo de diferenças em diferenças para Língua Portuguesa e Matemática. Em ambos os casos, a variável dependente é a nota média municipal no SAEB, calculada a partir das médias dos 5º e 9º anos do ensino fundamental. O grupo tratado corresponde aos municípios com baixa adoção de estratégias não presenciais durante a suspensão das aulas presenciais.

As Figuras 1 e 2 apresentam a evolução das notas médias para Língua Portuguesa e Matemática, respectivamente. Em ambas as disciplinas, os municípios classificados como sem estratégia apresentam desempenho médio inferior ao dos municípios com estratégia em todos os anos observados. Essa diferença persistente de nível indica que os grupos já eram distintos antes da pandemia, o que recomenda cautela na interpretação causal dos resultados.

Apesar dessa diferença, as séries apresentam movimentos semelhantes em parte do período anterior ao choque, com aumento das médias até 2019. Em 2021, primeiro ano observado após o início da pandemia, há queda nas duas disciplinas e nos dois grupos. A queda é visualmente mais acentuada no grupo sem estratégia, tanto em Língua Portuguesa quanto em Matemática. Esse padrão é compatível com a hipótese de que a baixa adoção de estratégias não presenciais esteve associada a perdas adicionais de aprendizagem.




Figura 1: Evolução da nota média do SAEB em Língua Portuguesa (5º e 9º anos)




Figura 2: Evolução da nota média do SAEB em Matemática (5º e 9º anos)

Tabela 3: Resultado do modelo de diferenças em diferenças para Língua Portuguesa

Dep. Variable:	media	R-squared:	0.010
Model:	OLS	Adj. R-squared:	0.010
Method:	Least Squares	F-statistic:	82.92
Date:	Fri, 12 Jun 2026	Prob (F-statistic):	1.77e-52
Time:	22:21:59	Log-Likelihood:	-1.7099e+05
No. Observations:	38535	AIC:	3.420e+05
Df Residuals:	38531	BIC:	3.420e+05
Df Model:	3		
Covariance Type:	cluster		

	coef	std err	z	P> z	[0.025	0.975]
Intercept	223.7410	0.230	971.161	0.000	223.289	224.193
sem_estrategia	-19.7651	1.397	-14.151	0.000	-22.503	-17.028
pos	0.8518	0.168	5.062	0.000	0.522	1.182
did	-4.0563	1.789	-2.268	0.023	-7.562	-0.551

Omnibus:	260.198	Durbin-Watson:	1.445
Prob(Omnibus):	0.000	Jarque-Bera (JB):	265.067
Skew:	-0.201	Prob(JB):	2.76e-58
Kurtosis:	2.948	Cond. No.	29.0

Notes:

[1] Standard Errors are robust to cluster correlation (cluster)

A Tabela 3 apresenta o resultado do modelo para Língua Portuguesa. O coeficiente da variável **sem_estrategia** é negativo e estatisticamente significativo, igual a -19,7651. Isso indica que, antes de considerar o efeito específico de 2021, os municípios classificados no grupo sem estratégia já apresentavam média cerca de 19,77 pontos inferior à dos municípios do grupo de controle.

O coeficiente da variável **pos** é positivo, igual a 0,8518, e estatisticamente significativo. Esse coeficiente representa a variação média do grupo de controle no período pós-tratamento, mantendo constante a diferença média entre tratados e controles. O coeficiente de interesse, associado ao termo **did**, é igual a -4,0563, com p-valor de 0,023. Como esse coeficiente é negativo e estatisticamente significativo ao nível de 5%, o resultado sugere que os municípios sem estratégia tiveram perda adicional de aproximadamente 4,06 pontos em Língua Portuguesa, em relação aos municípios com estratégia.

Tabela 4: Resultado do modelo de diferenças em diferenças para Matemática

Dep. Variable:	media	R-squared:	0.014
Model:	OLS	Adj. R-squared:	0.014
Method:	Least Squares	F-statistic:	221.0
Date:	Fri, 12 Jun 2026	Prob (F-statistic):	1.77e-135
Time:	22:21:59	Log-Likelihood:	-1.7301e+05
No. Observations:	38535	AIC:	3.460e+05
Df Residuals:	38531	BIC:	3.461e+05
Df Model:	3		
Covariance Type:	cluster		

	coef	std err	z	P> z	[0.025	0.975]
Intercept	233.2632	0.259	900.818	0.000	232.756	233.771
sem_estrategia	-22.2245	1.366	-16.264	0.000	-24.903	-19.546
pos	-3.0346	0.164	-18.495	0.000	-3.356	-2.713
did	-2.9667	1.725	-1.720	0.085	-6.347	0.413

Omnibus:	18.495	Durbin-Watson:	1.459
Prob(Omnibus):	0.000	Jarque-Bera (JB):	20.421
Skew:	-0.003	Prob(JB):	3.68e-05
Kurtosis:	3.113	Cond. No.	29.0

Notes:

[1] Standard Errors are robust to cluster correlation (cluster)

A Tabela 4 apresenta o resultado do modelo para Matemática. Assim como em Língua Portuguesa, o coeficiente da variável **sem_estrategia** é negativo e estatisticamente significativo, igual a -22,2245. Esse resultado indica que os municípios sem estratégia já apresentavam média cerca de 22,22 pontos inferior à dos municípios com estratégia antes

de considerar o efeito específico do período pós-pandemia.

O coeficiente da variável **pos** é negativo, igual a -3,0346, e estatisticamente significativo, indicando queda média no grupo de controle no período pós-tratamento. O coeficiente de interesse, **did**, é igual a -2,9667, com p-valor de 0,085. Portanto, o efeito estimado para Matemática também é negativo, indicando perda adicional de aproximadamente 2,97 pontos para os municípios sem estratégia. No entanto, esse resultado é estatisticamente significativo apenas ao nível de 10%, e não ao nível de 5%.

Em conjunto, os resultados apontam para pior evolução relativa dos municípios com baixa adoção de estratégias não presenciais nas duas disciplinas analisadas. A evidência é mais forte para Língua Portuguesa, onde o coeficiente de diferenças em diferenças é significativo a 5%. Em Matemática, o sinal do coeficiente é compatível com a hipótese do trabalho, mas a evidência estatística é mais fraca. Além disso, a magnitude dos coeficientes de **sem_estrategia** confirma que os grupos já eram substancialmente diferentes antes da pandemia. Assim, os resultados devem ser interpretados como evidência de associação entre baixa adoção de estratégias educacionais e pior evolução do desempenho, com cautela quanto a uma interpretação causal forte.

5 Conclusão

REFERÊNCIAS

BASE DOS DADOS. **Base dos Dados**. [S. l.: s. n.]. Disponível em:
<https://github.com/basedosdados/sdk>.

BECKER, Gary S. Human Capital: A Theoretical and Empirical Analysis, with Special Reference to Education — Front Matter. *In*: HUMAN Capital: A Theoretical and Empirical Analysis, with Special Reference to Education (2nd ed.) 2. ed. New York: National Bureau of Economic Research / Columbia University Press, 1975. Acessado em 19/10/2025. ISBN 0-87014-513-4. Disponível em:
<https://www.nber.org/system/files/chapters/c3730/c3730.pdf>.

BOF, Alvana Maria; MORAES, Gustavo Henrique. Impactos da pandemia no aprendizado dos estudantes brasileiros: desigualdades e desafios. **Cadernos de Estudos e Pesquisas em Políticas Educacionais**, v. 7, 2022. DOI:
[10.24109/9786558010630.ceppe.v7.5586](https://doi.org/10.24109/9786558010630.ceppe.v7.5586). Disponível em:
<https://doi.org/10.24109/9786558010630.ceppe.v7.5586>. Acesso em: 29 jun. 2026.

CHAVES, Marcelo Santos; SILVA, David Costa Correia;
CARVALHO SILVA, Charlene de. **A Relação da Formação de Capital Humano com o Desempenho Econômico Brasileiro**. [S. l.], jan. 2019. (Planejamento e Políticas Públicas (PPP), 52). Acessado em 18/10/2025. Disponível em:
<https://repositorio.ipea.gov.br/server/api/core/bitstreams/41bf00f5-8805-4ae4-bc5b-0406d34bea9c/content>.

FRAGA, Gilberto Joaquim; BACHA, Carlos José Caetano. Abertura comercial, capital humano e crescimento econômico no Brasil. **Pesquisa e Planejamento Econômico**, v. 43, n. 2, p. 384–418, 2013. Acessado em 19/10/2025. Disponível em:
<https://repositorio.ipea.gov.br/entities/publication/c4510f51-d83e-4f67-8e50-b877d84a0657>.

FUNDO DAS NAÇÕES UNIDAS PARA A INFÂNCIA (UNICEF); CENTRO DE ESTUDOS E PESQUISAS EM EDUCAÇÃO, CULTURA E AÇÃO COMUNITÁRIA (CENPEC). **Cenário da exclusão escolar no Brasil: um alerta sobre os impactos da pandemia da Covid-19 na educação**. Brasília, DF, 2021. Disponível em:
<https://www.unicef.org/brazil/media/14026/file/cenario-da-exclusao-escolar-no-brasil.pdf>. Acesso em: 29 jun. 2026.

INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA (IBGE). **Síntese de indicadores sociais: uma análise das condições de vida da população brasileira: 2021**. Rio de Janeiro: IBGE, 2021. 203 p. (Estudos e Pesquisas. Informação Demográfica e Socioeconômica, 44). ISBN 978-65-87201-98-6. Disponível em:
<https://biblioteca.ibge.gov.br/index.php/biblioteca-catalogo?id=2101892&view=detalhes>. Acesso em: 29 jun. 2026.

INSTITUTO NACIONAL DE ESTUDOS E PESQUISAS EDUCACIONAIS ANÍSIO TEIXEIRA (INEP). **Resultados do Questionário “Resposta Educacional à Pandemia de Covid-19 no Brasil” – Censo Escolar da Educação Básica 2020.** [S. l.], 2021. Acessado em 20/10/2025. Disponível em: https://download.inep.gov.br/censo_escolar/resultados/2020/apresentacao_pesquisa_covid19_censo_escolar_2020.pdf.

MINCER, Jacob A. Schooling, Experience, and Earnings. **National Bureau of Economic Research (NBER)**, 1974. Accessed: 2026-01-28. Disponível em: <https://www.nber.org/books-and-chapters/schooling-experience-and-earnings>.

SCHULTZ, Theodore W. Investment in Human Capital. **The American Economic Review**, American Economic Association, v. 51, n. 1, p. 1–17, 1961. ISSN 00028282. Disponível em: <https://la.utexas.edu/users/hcleaver/330T/350kPEESchultzInvestmentHumanCapital.pdf>. Acesso em: 18 jan. 2026.